Потребительские профили муниципалитетов

Динамические сети сходства и устойчивость кластеризации

2016 муниципалитетов
24 месяца: 2023–2024
4 метода и 21 альтернатива основному разбиению

Экономические различия профилей содержательны. Границы сообществ чувствительны к методу, поэтому устойчивую типологию выбранная процедура не подтверждает.

Код, данные и отчёт: github.com/roshlight/sberindex-clustering-submission

Помесячная сеть сходства профилей

Пять показателей: продовольствие, здоровье, маркетплейсы, общественное питание и транспорт. Нормируем каждое значение на сумму пяти категорий.

Вес связи: сумма квадратных корней произведений соответствующих компонент двух профилей. Каждый МО выбирает 20 ближайших соседей; используем объединение списков.

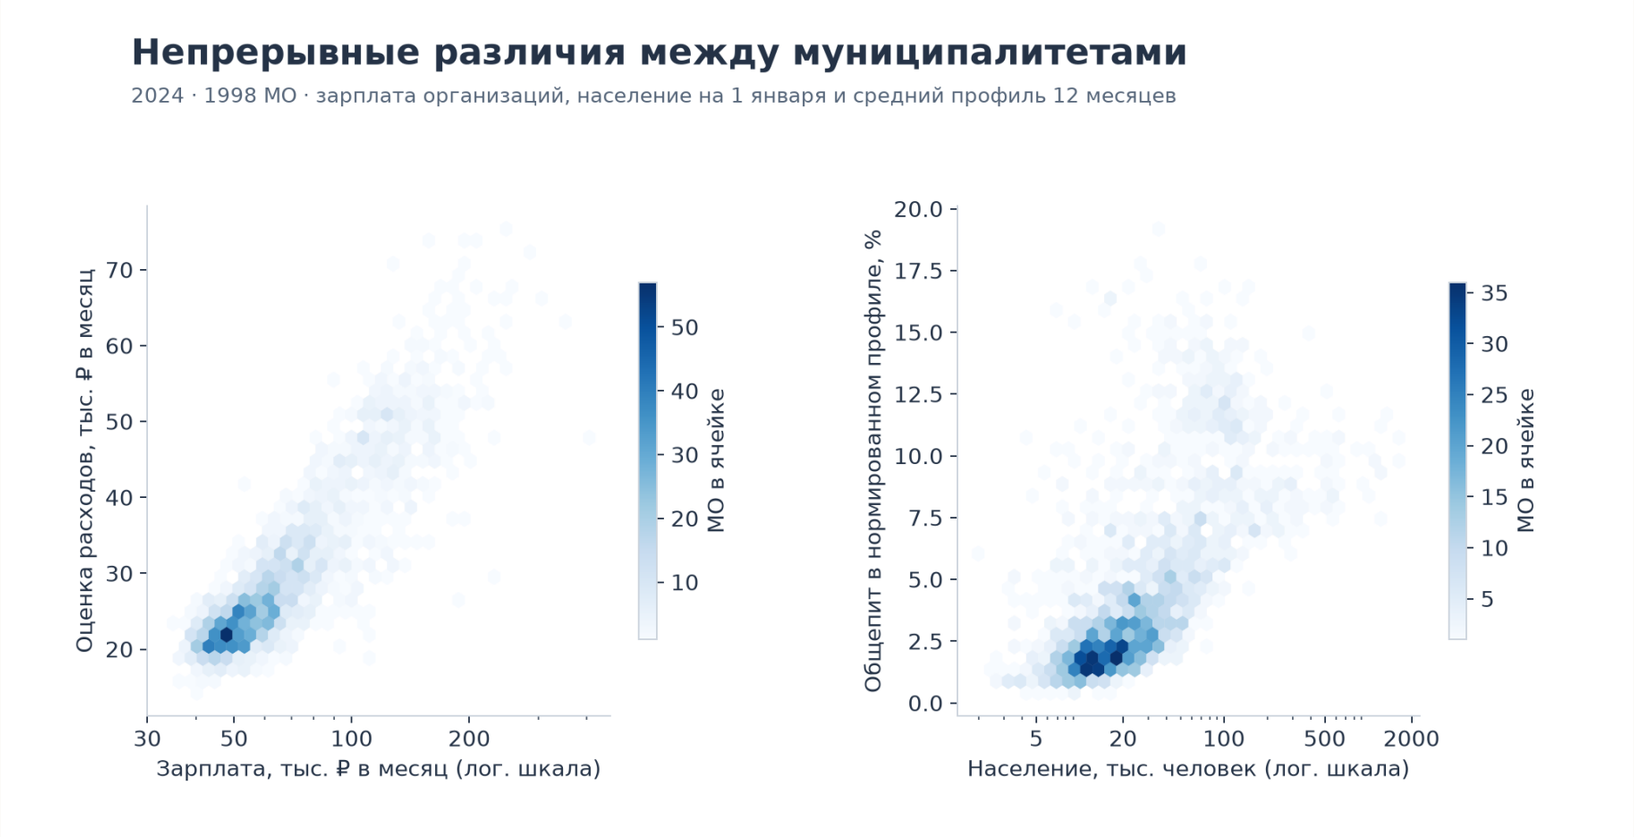
Основной метод: Leiden, разрешение 1,0, seed 13. Сравнения: косинусная сеть и KMeans с фиксированным и сопоставимым числом групп.

Профили описывают соотношения опубликованных средних. Они не равны точным долям семейного бюджета; рёбра не измеряют реальные потоки.

Источники: reports/initial_study/REPORT.md; configs/robustness_v1.json

Экономические различия имеют непрерывный характер

Население, зарплата и концентрация рабочих мест помогают описывать потребительские профили.

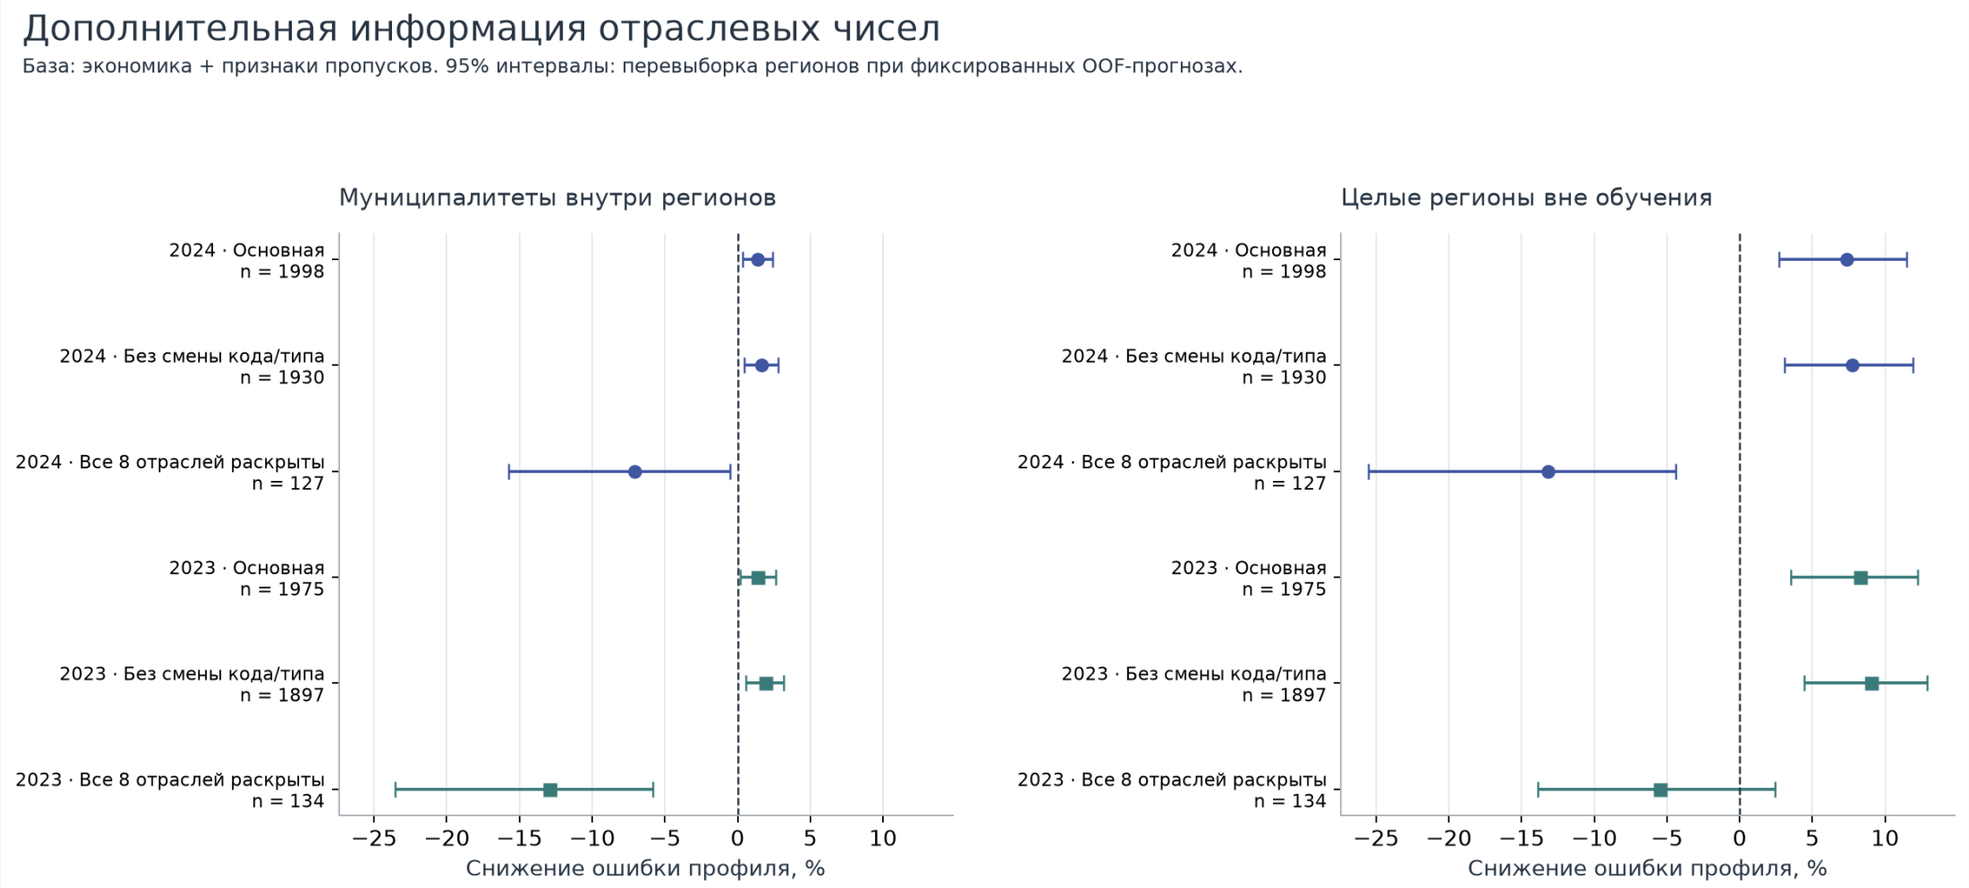


Связи описательные. Зарплата организаций отличается от дохода жителей, рабочие места от занятых жителей.

Источник: reports/enriched_analysis/REPORT.md, парно доступные данные 2024 года

Отрасли добавляют информацию о составе профиля

2024: снижение ошибки на 1,38% внутри регионов и 7,34% при удержании целых регионов.



На малой выборке с полным раскрытием отраслей качество ухудшается. Интервалы не учитывают повторное обучение.

Источник: reports/round2_analysis/REPORT.md; проценты относятся к квадратичной ошибке CLR-профиля

Метрики отражают разные свойства групп

Медианы по 12 месяцам 2024 года

Метод	SW ↑	CH ↑	AVI ↑	AVU ↓	MQ ↑
Leiden, Хеллингер	0,163	785,31	0,815	0,537	0,716
Leiden, косинус	0,119	688,64	0,857	0,543	0,750
KMeans, K = 8	0,249	1079,86	0,822	0,540	0,689
KMeans, сопоставимое K	0,226	939,77	0,788	0,525	0,690

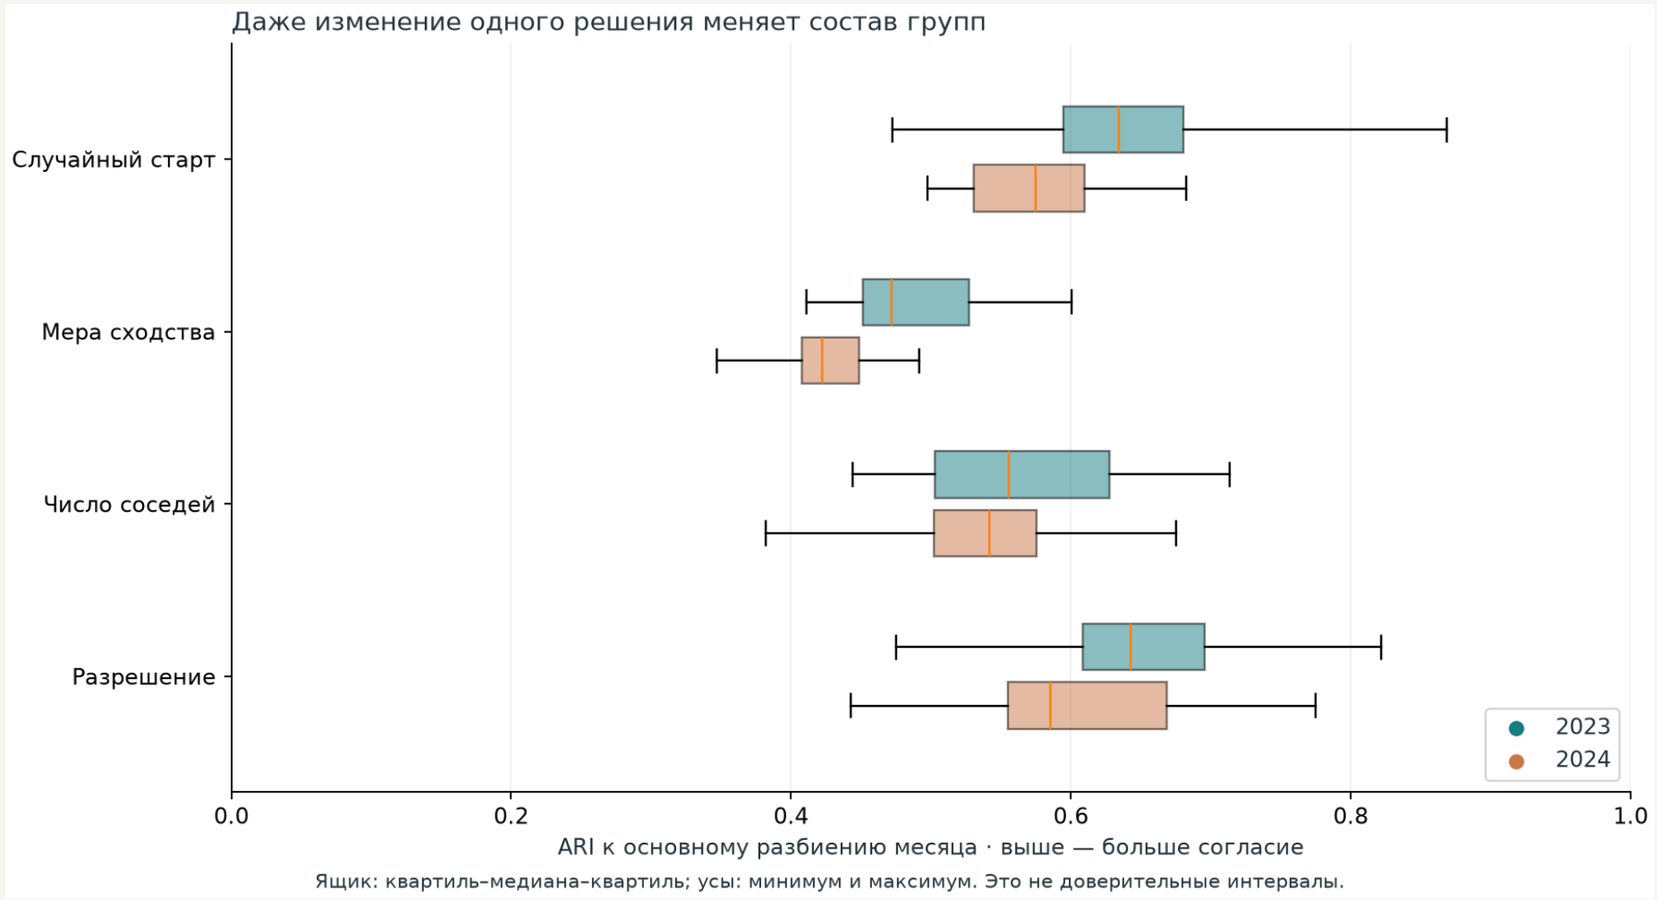
S_Dbw определён в 2/12, 8/12, 8/12 и 0/12 месяцев по порядку строк. Неопределённые значения не заменены нулём.

Косинусный Leiden оценивается на другой сети. По AVU основной метод хуже контрольных перестановок. Общего положительного вердикта всех метрик нет.

Источники: reports/initial_study/method_metrics.csv; docs/metrics.md

Состав групп зависит от методических решений

ARI сравнивает разбиения независимо от номеров меток. Единица соответствует полному совпадению.



Чувствительность возникает при смене геометрии, числа соседей, разрешения и даже случайного старта.

Источник: reports/initial_study/REPORT.md

Поддержка отдельных назначений мала

Альтернатива поддерживает назначение при Jaccard состава группы ≥ 0,8. Требуется минимум 17 из 21 альтернативы.

2023: 66 из 24 192 назначений

2024: 0 из 24 192 назначений

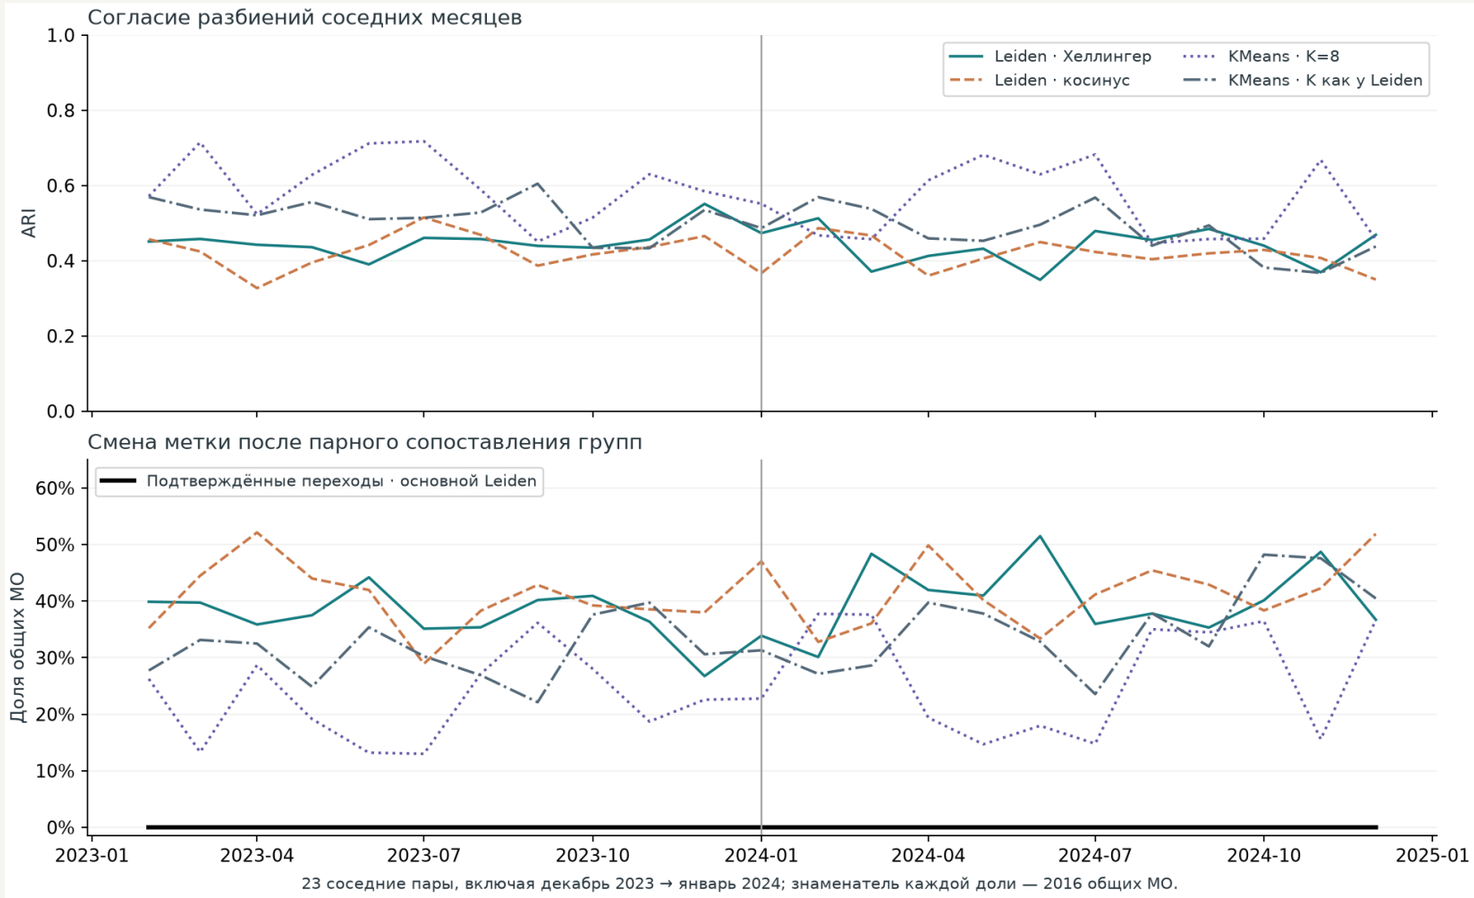
Все 66 назначений относятся к августу 2023 года. Порог операционный: он не измеряет вероятность истинности экономического типа.

Годовое сглаживание не восстановило поддержку Leiden. Межгодовой ARI годового Leiden: 0,3253; KMeans с K = 8: 0,6631. Это не подтверждение восьми истинных типов.

Источники: reports/initial_study/REPORT.md; reports/enriched_analysis/annual_networks/README.md

Сырые смены групп требуют проверки

18 008 смен на 46 368 пар соседних месяцев. Ни одна не проходит парный фильтр основного Leiden.

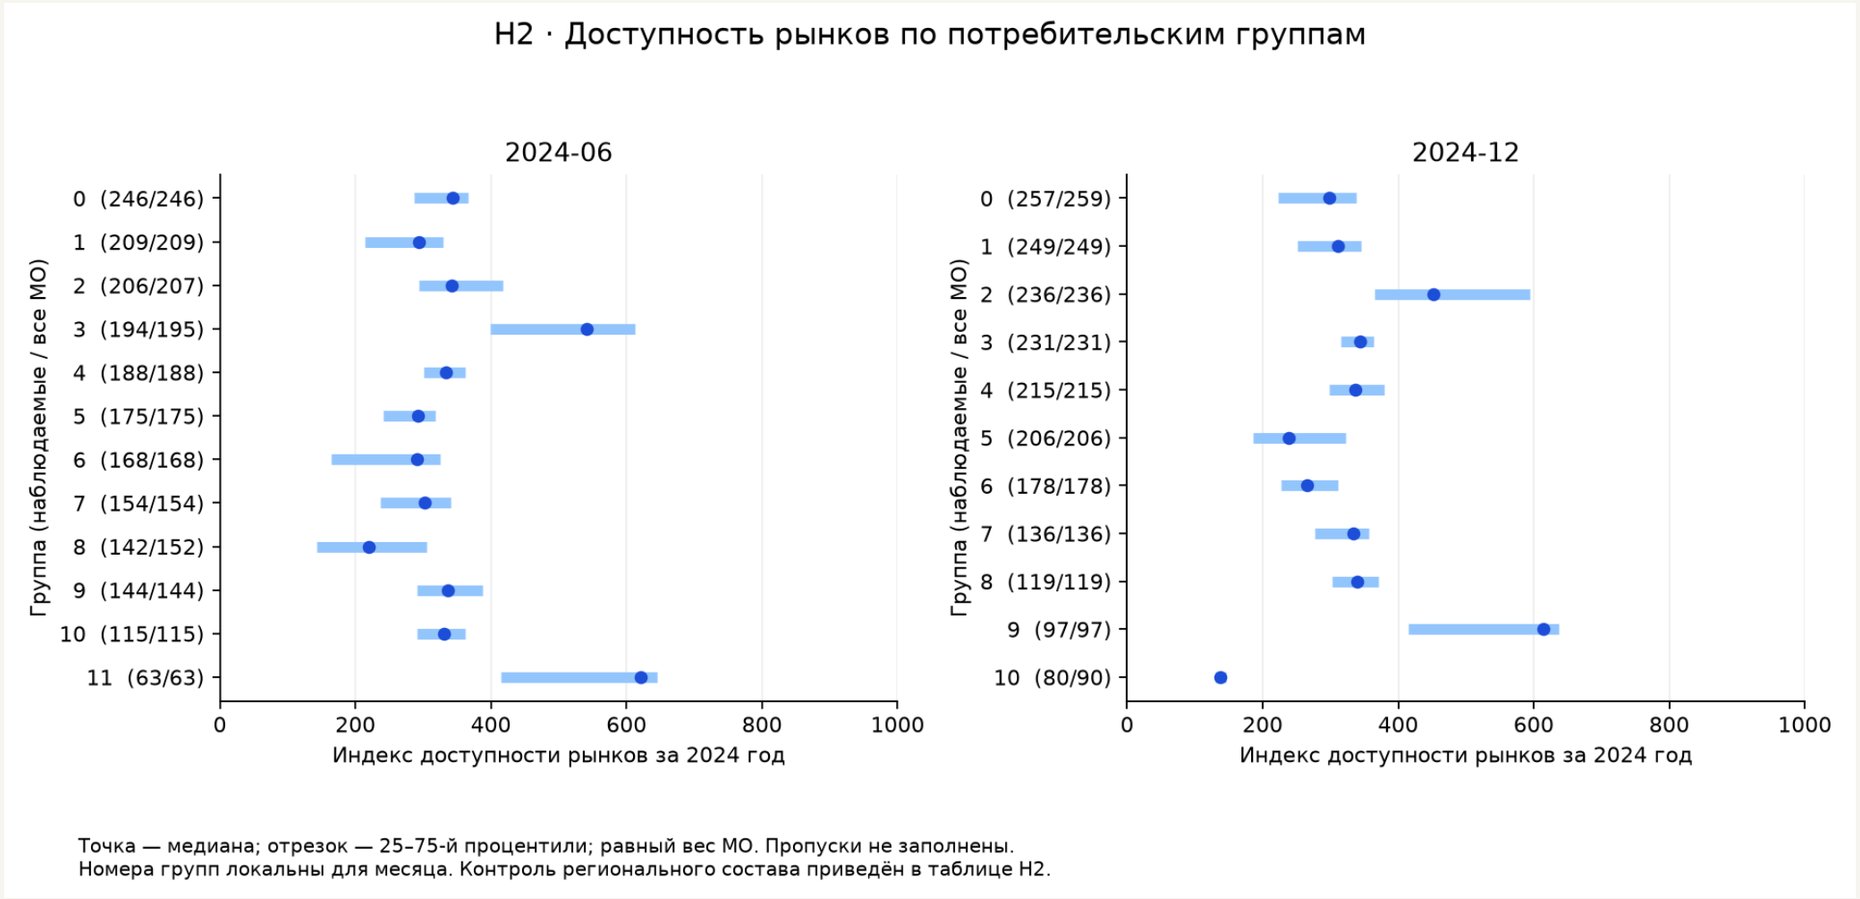


Максимум совместной поддержки концов 14/21 при требовании 17/21. Нулевой итог не доказывает отсутствия изменений экономики.

Источник: reports/initial_study/REPORT.md; после попарного согласования меток

Доступность рынков различается между группами

В обоих месяцах различия превышают условный случайный ориентир с сохранением регионального состава.



Проверка ретроспективная. Размер МО и пространственная автокорреляция дополнительно не контролируются.

Источник: docs/reviews/spatial_validation.md; доступность рынков за 2024 год

Применение и границы результата

Потребительские профили дают материал для сравнения территорий. Отрасли и пространственный контекст помогают интерпретировать наблюдаемые различия.

Жёсткая метка зависит от метода. Для индивидуального назначения и перехода требуется проверка поддержки; подтверждённого списка экономических шоков здесь нет.

Дополнения инвестиций, отгрузки и розницы не дали устойчивого прироста модели профиля. Документальные кейсы сохранены с ограничениями сопоставимости.

Основная процедура проверена на 2024 годе после фиксации на 2023-м. Последующие анализы исследовательские. Панель ретроспективная, история ограничена 24 месяцами.

Методология, код, таблицы и архивы: github.com/roshlight/sberindex-clustering-submission